

From Incidents to Framing: a Dutch and English Frame-Semantic Corpus and Lexicon



Piek Vossen, Pia Sommerauer, Levi Remijnse
Vrije Universiteit Amsterdam
De Boelelaan 1105, 1081HV, Amsterdam, The Netherlands
piek.vossen@vu.nl, pia.sommerauer@vu.nl, levi_remijnse@hotmail.com

LREC-2026, Mallorca



Framing in the Dutch language


Overview

- Results of a 5 year project:
 - **comparable** FrameNet and (co-)Reference resources (corpora and lexicon) for Dutch, and possibly other languages
 - Applying the data-to-text method (Vossen et al. 2018) to create a **referentially grounded corpus**
 - **Frame and Reference annotations** by students (Dutch and English) and **automatic Frame annotations** for English (OpenSesame, Swayamdipta et al. 2017)
 - Analyses of framing the same and similar incidents across languages, cultures and contexts

MWEP: Data-to-Text Platform



basic level event (25 in total):
local maximum
in an event hierarchy



Typical frames per event type (using open-sesame)


election	Frame	Freq
	Change_of_leadership	686
	Leadership	443
	Interior_profile_relation	340
	Calendric_unit	280
	Ordinal_numbers	255
	Time_vector	211
	Aggregate	191
	Cardinal_numbers	183
	Getting	158
	Containing	155

murder	Frame	Freq
	Killing	129
	Attack	108
	Calendric_unit	95
	Cardinal_numbers	71
	Statement	61
	Leadership	60
	People	58
	Locale_by_use	52
	Weapon	50
	Time_vector	49


FF.ICF metric,
where CF is the number of
collections in which a frame
occurs, and FF is the frame
frequency in that collection

**Collection of reference texts
to incidents of a basic level
event type**

MWEP: Data-to-Text Platform



MWEP: Data-to-Text Platform



Referentially grounded texts

Gökmen Tanis bekent **schietpartij** in tram in Utrecht.

Gökmen Tanis heeft de dodelijke **schietpartij** maandagochtend op het 24 Oktoberplein in Utrecht bekend. Dat heeft het Openbaar Ministerie zojuist bekendgemaakt. **Hij** zegt alleen gehandeld te hebben. De rechter-commissaris verlengde vandaag zijn voorarrest met de maximale termijn van veertien dagen. Het OM verdenkt **hem** van meervoudige moord met een terroristisch oogmerk. Tot nu toe is niets gebleken van een relatie tussen de **schutter** en zijn **slachtoffers**. **Hij** doodde in en rond een tram **drie mensen** en verwondde er **vijf** met een pistool.

A **gunman** has opened fire inside a tram in the Dutch city of Utrecht.

Several people have been injured and one is feared to have died in the shooting at about 10:45 local time (09:45 GMT) near the 24 Oktoberplein junction, reports say. Police say the **gunman** is still at large. The area has been cordoned off, trams stopped and schools have been asked to keep their doors closed. Counter-terror police reportedly say **it** has all the marks of a **terror attack**.

Incident: 2019 Utrecht shooting

Shooter: Gökmen Tanis

Victim: Rinke Terpstra

Target: Utrechtse sneltram

Where: 24 Oktoberplein-Zuid

When: 18 March 2019

Nr. of injured: 6

Nr. of death: 4

test_release

aircraft shootdown@en

Malaysia Airlines Flight 17

nl

298 doden bij Malays

Select Annotation Type:

Frame Annotation

Save

Clear selection

Select Annotation Task:

Remove

Select Typicality range:

298 doden bij Malaysia-crash ([source](#))

In Oekraïne is een **passagier**_s **vliegtuig** van Malaysia Airlines **neergestort** dat in **Amsterdam** is **opgestegen**. Malaysia Airlines bevestigt dat **vlucht** MH17 wordt **vermist**. Dat **gebeurde** in de buurt van Donetsk op 50 kilometer van de Russische grens. Malaysia Airlines zegt in een verklaring dat het toestel 283 passagiers en 15 bemanningsleden **aan boord had**. Daar **zitten** veel Nederlanders **bij**, zei minister Opstelten. Hoeveel is nog onduidelijk. Het toestel was om 12.14 uur van Schiphol **opgestegen**. Het zou om 00.10 Nederlandse tijd in **Kuala Lumpur** **aankomen**. KLM Vlucht MH17 van Malaysia Airlines is een gecombineerde lijndienst van Malaysia Airlines en KLM, die dagelijks op Kuala Lumpur vliegt. Het KLM - vluchtnummer was KL4103. KLM zegt in een verklaring dat het met leedwezen kennis heeft genomen van " een mogelijk **incident** " met deze **vlucht**. " We staan in contact met Malaysia Airlines om meer informatie te krijgen. " Schiphol heeft een GRIP2-procedure in werking gezet waardoor er hulp_**verleners** naar de luchthaven zijn **gekomen**. Die worden ingezet om familie en vrienden van inzittenden op te vangen. Neergehaald Een adviseur van de Oekraïense regering heeft tegen Interfax gezegd dat alle inzittenden zijn **omgekomen**. Verder zegt hij dat het toestel door pro - Russische **separatisten** met een raket uit de lucht is **gehaald**. President Porosjenko spreekt van een **terroristische daad**. De Europese organisatie voor veiligheid in de Luchtvaart, Eurocontrol, zegt dat het toestel 10 kilometer hoogte **vloog** toen het van de radar **verdween**. Het **toestel vloog** op een hoogte die door de Oekraïense luchtvaart_autoriteiten als veilig was **bestempeld**. Honderden meters lager lag een gebied waar geen burgervliegtuigen mochten komen. Na de **crash** is het lucht_ruim boven Oost - Oekraïne volledig **gesloten**. Buk De **separatisten beschikken** sinds kort over Buk - raketten van Russische makelij, ook bekend als SA11- en SA17-raketten. De **separatisten ontkennen** dat. Zij **zeggen** dat ze niet over de middelen **beschikken** om een toestel dat zo hoog **vliegt** uit de lucht te **schieten**. Getuigen op de grond zeggen dat de wrak_stukken over een groot verspreid liggen. Dat wijst erop dat het toestel in de lucht uit elkaar is **gevallen** of **geschoten**. Zwarte doos **Separatisten** hebben tegen persbureau Interfax **gezegd** dat ze een zwarte doos van het toestel hebben **gevonden**. Leiders van de **separatisten zeiden** eerder al dat die aan Rusland wordt **overgedragen**. De Oekraïense premier zegt dat hij het **neerstorten** van het toestel laat **onderzoeken** en dat zijn troepen niet op luchtdoelen hebben geschoten. De minister van Defensie zegt dat niet vaststaat dat het toestel is **neergehaald**. Onderzoek Een onderzoek naar de oorzaak van een vliegcrash wordt in principe gedaan door het land waar de ramp zich voordeed. Zo is dat internationaal afgesproken. Een land dat veel slachtoffers te betreuren heeft, kan de rol van waarnemer krijgen. President Porosjenko zegt dat Nederlandse experts zijn uitgenodigd om aan het **onderzoek** mee te doen. In Nederland is de Onderzoeksraad voor Veiligheid dan de aangewezen instantie. Dat was ook het geval bij het onderzoek naar het neerstorten van een toestel van Afriqiyah Airways bij Tripoli in 2010. Noodnummers D - reizen zei tegen de NOS dat deze **vlucht** door 25 klanten is **geboekt**. Een deel had Kuala Lumpur als eindbestemming, anderen wilden doorvliegen naar Australië en Nieuw - Zeeland. Drie van hen hebben hun reis op het laatste moment omgeboekt. Voor familieleden stelt D - reizen een noodnummer in : 023 - 5542555. Het ministerie van Buitenlandse Zaken heeft ook een noodnummer ingesteld : 070 - 3487770. Familieleden van mensen die **aan boord** waren, kunnen daar terecht met hun vragen terecht. Malaysia Airlines heeft ook een alarmnummer : 0060 - 378841234. De Franse minister Fabius van Buitenlandse Zaken heeft gezegd dat er ten minste vier Fransen aan boord waren. Mogelijk waren er ook Belgen aan boord. Het Belgische ministerie van Buitenlandse Zaken heeft eveneens een noodnummer ingesteld : 0032 - 25014000. Boeing Vliegtuigbouwer Boeing heeft een verklaring op zijn website gezet : " Onze gedachten en gebeden zijn bij de mensen **aan boord** van het vliegtuig van Malaysia Airlines dat boven Oekraïne wordt **vermist**, en ook bij hun families en hun geliefden. "

Structured Data

incident type: [aircraft shootdown@en](#)
(Q6539177)
incident ID: [Malaysia Airlines Flight 17@en](#)
(Q17374096)
hasPlace: [Ukraine](#)

hasActor: [victims](#), [Pro-Russian rebels](#), [aircraft](#),
[bemanningsleden](#), [53rd brigade](#), [Oleg Ivannikov](#),
[Russia](#), [Vladimir Tsemach](#), [Ukraine](#), [Oleg](#)
[Poelatov](#), [Sergej Doebinski](#), [Igor Girkin](#), [Leonid](#)
[Chartsjenko](#)

Selected predicate

Label: Ride_vehicle
Term POS: VERB
Premon: [Click here](#)
FrameNet: [Click here](#)
Predicate ID: pr23
Frame Relation: type

Frame Element	Role Type	Annotated	Expressed
Theme	Core	true	true
Vehicle	Core	true	true
Source	Core	true	true
Path	Core	true	false
Goal	Core	true	true
Area	Core	true	false

Final data

	total	en	nl	both
types	38	37	28	27
incidents	22,058	22,002	2,333	2,277
texts	28,642	25,648	2,993	n.a.
<i>human-annotated</i>	1,312	975	337	n.a.
<i>system-annotated</i>	24,670	24,670	0	n.a.
primary reference texts	7,903	6,729	1,173	n.a.
<i>human-annotated</i>	1,312	975	337	n.a.
<i>system-annotated</i>	5,751	5,751	0	n.a.
secondary reference texts	20,739	18,919	1,820	n.a.
<i>human-annotated</i>	0	0	0	n.a.
<i>system-annotated</i>	18,919	18,919	0	n.a.
token-count of annotated texts	4,839,844	4,431,000	408,251	n.a.
<i>human-annotated</i>	699,876	583,683	116,193	n.a.
<i>system-annotated</i>	3,844,778	3,844,778	0	n.a.

Table 1: Overview of annotated texts.

English	inc.	texts	ratio
aircraft shootdown	1	182	182.0
disease outbreak	2	189	94.5
natural disaster	1	48	48.0
music festival	15	554	36.93
economic crisis	4	119	29.75
royal wedding	17	320	18.82
mass shooting	88	997	11.33
legal case	40	383	9.57
riot	74	448	6.05
storm	61	260	4.26
auto race	138	181	1.31
<i>unknown</i>	1,180	1,296	1.1
festival	35	38	1.09
presidential elec- tion	3,008	3,235	1.08
multi-sport event	317	322	1.02
association football competition	41	42	1.02
local election	4,066	4,093	1.01
legislative election	2,395	2,408	1.01
tennis tournament	3,378	3,410	1.01
championship	550	556	1.01
stage race	86	87	1.01
marathon	39	39	1.0
holiday	2	2	1.0
ceremony	1,139	1,140	1.0
tournament	25	25	1.0
single-day road race	1,574	1,574	1.0
round	52	52	1.0
military operation	2,203	2,210	1.0
contract	7	7	1.0
1.1 (cycling race)	100	100	1.0
motorcycle race	633	634	1.0
rally	161	161	1.0
regatta	51	51	1.0
annual event	21	21	1.0
1.2 (cycling race)	57	57	1.0
golf tournament	201	201	1.0
wrestling event	205	206	1.0

Dutch	inc.	texts	ratio
aircraft shootdown	1	161	161.0
disease outbreak	2	291	145.5
natural disaster	1	18	18.0
riot	5	58	11.6
music festival	5	54	10.8
mass shooting	10	76	7.6
legal case	1	4	4.0
wrestling event	28	42	1.5
<i>unknown</i>	118	135	1.14
association football competition	5	5	1.0
local election	4	4	1.0
auto race	1	1	1.0
regatta	3	3	1.0
presidential elec- tion	5	5	1.0
tournament	6	6	1.0
rally	146	146	1.0
golf tournament	26	26	1.0
multi-sport event	98	98	1.0
championship	72	72	1.0
festival	14	14	1.0
marathon	37	37	1.0
ceremony	96	96	1.0
tennis tournament	898	899	1.0
motorcycle race	557	557	1.0
legislative election	175	175	1.0
contract	5	5	1.0
annual event	6	6	1.0

Annotation results

Inter-annotator-agreement

1. instance-links	
span matches	89.5%
agreement on span matches	89.4%
2. frames	
span matches	73.7%
agreement on span matches	91.9%
similarity in disagreement	0.59
similarity p-value	0.07
3. frames and instance-links	
joint agreement	97.58%
disjoint agreement	89.94%
joint:disjoint ratio	1:2.3
4. frame elements	
agreement incl. unexpressed FE's	69.5%
agreement excl. unexpressed FE's	94.0%

Classical annotation:

- select frame for main predicate:
47% IAA.
- select frame element given a main
frame: 79%

	en man	sys	nl man
mass shooting	292	705	68
music festival	220	334	45
aircraft shootdown	172	7	148
royal wedding	151	169	0
legal case	122	261	1
storm	12	248	0
presidential election	4	3,231	0
riot	2	446	50
1.2 (cycling race)	0	57	0
annual event	0	21	0
association football competition	0	42	0
regatta	0	51	0
economic crisis 9	0	119	0
contract	0	7	0
holiday	0	2	0
1.1 (cycling race)	0	100	0
disease outbreak	0	189	17
natural disaster	0	48	8
festival	0	38	0
legislative election	0	2,408	0
local election	0	4,093	0

Out-of-sentence relations

26.4% of frame elements outside the frame sentence.

99.8% of frames at least one sentence-external frame element (avg. 1.58 frame element per frame).




Figure 1: Number of sentence-external frame elements with the distance in sentences to the annotation of the frame. The figure includes the agreement score for each distance to the frame.

FrameNet and ReferenceNet lexicons

derived annotated corpora and monosemous mappings

Dutch FrameNet v1.0	Counts
Total entries	6,964
Nouns	2,883
Names	218
Verbs	2,621
Adjectives	530
Frames per entry	3.01
Annotation per entry	12.41
Total annotations	28,670
Frame coverage	2,311
Manual annotations	27,841
Lexical baseline	829
Data-to-text annotations	22,435
RBN-Wordnet-FrameNet mappings	954
Sonar annotations	5,281

Table 6: Overview of the Dutch FrameNet lexicons combining three data sets: Data2Text corpus, the RBN-WordNet-FrameNet mapping and the SoNaR annotations

- F-lex: lexicon of forms annotated with a frame.
- FE-lex: lexicon of forms annotated as frame elements.
- R-lex: lexicon of forms referring to entity and event instances

Lexicon	Total entries	Nouns	Names	Verbs	Adj	Frames per entry	Annotations per entry	Total Annotations	Total Frames
F-lex-nl	2,662	1,003	48	1,019	212	4.14	18.64	11,986	643
FE-lex-nl	3,588	2,159	195	532	257	2.00	14.19	25,494	1,796
F-lex-en	7,194	2,778	591	2,157	1,170	7.63	973.57	918,079	943
FE-lex-en	6,121	2,490	1,879	856	401	2.85	35.03	75,146	2,145

Table 5: Statistics on the FrameNet lexicons for Dutch (nl) and English (en) derived from the manual and automatic (Open-SESAME) annotations. Separate lexicons are derived from the frame (F) and frame element (FE) annotations. Total entries are given, as well as the main part-of-speech division. Polysemy is represented by the average frames per entry. Further columns give the average number of annotations per entry, the total annotations and the number of distinct frames and frame elements covered.

Lexicon	Total entries	Nouns	Names	Verbs	Adj.	Referents per entry	Annotations per entry	Total annotations	Total referents
R-lex-nl	3,170	472	88	39	73	11.01	34.21	9,852	288
R-lex-en	8,005	282	743	46	61	12.65	62.68	39,676	633

Table 7: Statistics on the Reference lexicons for Dutch (nl) and English (en) derived from the manual annotations with Wikidata identifiers. Total number of entries are broken down by the main part-of-speech. Referents per entry shows the average polysemy in making reference, whereas annotations per entry shows the average number of references annotated. Total referents are the unique Wikidata identifiers referred to.

- Vossen, P., and Fokkens, A., and Maks, I., and van Son, C.. 2018. "Towards an open Dutch Framenet lexicon and corpus." LREC208
- Vossen, P., F. Ilievski, M. Postma "ReferenceNet: a semantic-pragmatic network for capturing reference relations" in: Proceedings of the 9th Global WordNet Conference 2018.

Examples of lexical entries

Frame lexicon

```
{
  "ramp:NOUN": {
    "lemma": "ramp",
    "pos": "NOUN",
    "frames": {
      "fn17-catastrophe": { }
    }
  },
  "betrokkenheid:NOUN": {
    "lemma": "betrokkenheid",
    "pos": "NOUN",
    "frames": {
      "fn17-participation": { }
    }
  },
  "onderzoek:NOUN": {
    "lemma": "onderzoek",
    "pos": "NOUN",
    "frames": {
      "fn17-criminal_investigation": { },
      "fn17-inspecting": { },
      "fn17-scrutiny": { },
      "fn17-research": { },
      "fn17-controller_object": { },
      "fn17-abandonment": { }
    }
  },
  "denken:VERB": { },
  "handelen:VERB": { },
  "meewerken:VERB": { },
  "neerhalen:VERB": {
    "lemma": "neerhalen",
    "pos": "VERB",
    "frames": {
      "fn17-downing": {
        "annotations": [
          {
            "project": "DutchFrameNet",
            "status": "manual",
            "annotator": "fYmWjPYXm-a941VDkG-Vr12dU_2LTh8f",
            "timestamp": "2021-10-24T19:34:28UTC",
            "reftype": "type",
            "mention": [
              {
                "doc": "33f08208-e72e-46b6-b074-b7d600868ae4.naf",
                "term": "t74",
                "tokens": [
                  {
                    "token_id": "w74",
                    "sent": "4",
                    "offset": "400",
                    "length": "9"
                  }
                ]
              }
            ]
          }
        ],
        "text": "Het neerhalen van vlucht"
      }
    }
  },
  "fn17-domination": { },
  "fn17-vehicle_landing": { }
}
```

Reference lexicon

```
{
  "belgië:NOUN": {
    "lemma": "belgië",
    "pos": "NOUN",
    "references": {
      "http://www.wikidata.org/entity/Q31": { },
      "http://www.wikidata.org/entity/Q46": { },
      "http://www.wikidata.org/entity/Q1649349783699": { }
    }
  },
  "de_ramp:DET_NOUN": { },
  "vlucht_mh17:NOUN_NOUN": {
    "lemma": "vlucht_mh17",
    "pos": "NOUN_NOUN",
    "references": {
      "http://www.wikidata.org/entity/Q1631864271612": {
        "annotations": [
          {
            "project": "DutchFrameNet",
            "status": "manual",
            "annotator": "undefined",
            "timestamp": "2021-10-24T19:20:40UTC",
            "reftype": "entity",
            "mention": [
              {
                "doc": "33f08208-e72e-46b6-b074-b7d600868ae4.naf",
                "term": "t15t16",
                "tokens": [
                  {
                    "token_id": "w15",
                    "sent": "1",
                    "offset": "102",
                    "length": "6"
                  },
                  {
                    "token_id": "w16",
                    "sent": "1",
                    "offset": "109",
                    "length": "4"
                  }
                ]
              }
            ],
            "text": "Verschillende landen willen dat Rusland verantwoording aflegt over zijn betrokkenheid bij de ramp met vlucht MH17 ."
          }
        ]
      }
    }
  },
  { },
  { }
}
```


Grounded Framing

What can you do with a referentially grounded resource?

- Multiple texts, across multiple languages that are referentially grounded to the same incident and the same entities.
- Many referentially grounded text about the same type of incident.
- Comparative analysis of framing and reference of the same incident or event:
 - by different authors, with different historical distance
 - across language & cultures
 - triggered by different contexts

Referent	Label	Most Frequent Men- tion	NL Frames	EN Frames	Overlap
Q159	Russia	Russia	105	202	65
Q17374096	Malaysia Airlines Flight 17	crash:NOUN	77	120	53
Q62116513	Gökmen Tanis	t. (Tanis)	113	88	41
Q1636580448374	None	Ukraine	60	124	31
Q1631864085791	None	rebel	38	201	31
Q1651075371225	None	organisier	47	116	25
Q1631025548534	None	slachtoffer (victim)	69	104	23
Q1631864271612	None	MH17	34	78	22
Q1646835057489	None	audience	35	135	21
Q29999	Kingdom of the Netherlands	nederland:NOUN	59	74	20
Q30973589	Eurovision Song Con- test 2020	contest	32	94	19
Q15821620	Joint investigation team	jit	51	43	19
Q1673010005817	None	nabestaande (surviv- ing relative)	59	54	17
Q1638962685452	None	artist	26	135	14
Q1689167507986	None	politie (police)	46	47	12
Q67197819	Volodymyr Tsemakh	tsemach	49	22	11
Q1632409367599	None	slachtoffer (victim)	33	30	10
Q1646212736373	None	rioter	74	20	10

Table 8: Most frequently referenced entities with their Wikidata label, if present, and the most frequent referring expression (English or Dutch). Columns show the number of unique Frames associated with the Dutch and English mentions and the number of overlapping Frames. If the Label is None, the entity is not in Wikidata but created by the annotator on the spot with a non-existing random Q-number

Framing across Dutch and English

Judgment by culture and context

Q159 (Russia)	NL&EN		EN
fn17-statement@speaker:	55	13	42
fn17-responsibility@agent:	48	36	12
fn17-affirm_or_deny@speaker:	47	12	35
fn17-criminal_investigation@suspect:	37	23	14
fn17-supply@supplier:	34	3	31
fn17-exchange@exchanger_1:	22	5	17

Gökmen Tanis	NL & EN	NL	EN
fn17-offenses@perpetrator	39	19	20
fn17-suspicion@suspect	33	11	22
fn17-hit_target@agent	29	17	12
fn17-attack@assailant	25	13	12
fn17-killing@killer	22	8	14
fn17-terrorism@terrorist	22	15	7
fn17-suspicion	21	7	13
fn17-trial@defendant	19	14	5
fn17-statement@speaker	11	9	2
fn17-committing_crime@perpetrator	12	8	4
fn17-use_firearm@agent	15	3	12
fn17-arrest@suspect	13	2	11
fn17-detaining@suspect	15	4	11
fn17-bearing_arms	0	0	11

rioter	NL & EN	NL	EN
fn17-chaos@entity	19	11	8
fn17-chaos@state	5	1	4
fn17-chaos	5	1	4
fn17-committing_crime@perpetrator	4	3	1
fn17-people	4	3	1
fn17-robbery@perpetrator	2	1	1
fn17-emotion_directed@experiencer	2	1	1
fn17-verdict@defendant	2	1	1
fn17-setting_fire@kindler	2	1	1
fn17-hostile_encounter@side_2	2	1	1
fn17-protest@protester	0	9	0
fn17-attack@assailant	0	8	0
fn17-causation@actor	0	6	0
fn17-arrest@suspect	0	5	0
fn17-cause_harm@agent	0	5	0
fn17-damaging@agent	0	4	0
fn17-destroying@destroyer	0	4	0
fn17-evading@evader	2	0	2
fn17-resolve_problem@problem	2	0	2

Conclusions

- Data-to-text method to create a freely available corpus of English and Dutch texts:
 - that are referentially grounded to events and entities in Wikidata
 - with the structured data for the events and entities that are referenced in the texts.
- Annotations of the corpus in terms of FrameNet frames, frame elements and Wikidata references.
- English and Dutch FrameNet & Reference lexicons derived from the annotations.
- Future work:
 - Extent the data to events mentioned in Wikipedia pages of entities:
 - Query Wikidata for all entities that suffered from an infectious disease
 - Extract the text in Wikipedia that mentions the disease, and extract any primary reference text that make reference to the entity suffering from it.
 - Train FrameNet labellers and (cross-document) co-reference resolution with our annotated data
 - Manually revise the FrameNet lexicon and map it to the Open Dutch Wordnet